



UNIVERSIDADE FEDERAL RURAL DO SEMI-ÁRIDO
CENTRO MULTIDISCIPLINAR DE PAU DOS FERROS
ENGENHARIA DA COMPUTAÇÃO
PROFESSOR DR. PEDRO THIAGO VALÉRIO DE SOUZA SISTEMAS INTELIGENTES

THIAGO GEOVANE DA COSTA NUNES

PROJETO 1: MODELO K-NN

PAU DOS FERROS – RN

2026

Sumário

1.INTRODUÇÃO..... 3

2. METODOLOGIA..... 3

3. RESULTADOS E DISCUSSÕES..... 3

4. CONCLUSÃO..... 6

ANEXO I..... 7

1. INTRODUÇÃO

Repositório: <https://github.com/Rated84/modelo-KNN.git>

Este trabalho tem como objetivo desenvolver um modelo de classificação de vinhos em categorias de qualidade, sendo as mesmas, respectivamente, baixa, média e alta. Tal classificação é feita com uso de **K-NN**.

2. METODOLOGIA

Para o treinamento foi feito uso do dataset Wine Quality disponível em: <https://archive.ics.uci.edu/ml/datasets/Wine+Quality>. O arquivo foi criado por Paulo Cortez et al.

Primeiramente, após o carregamento do dataset, é feita uma recodificação da qualidade definindo a mesma em três classes (**ruim, média, bom**). Posteriormente foi feita a normalização, visto que o K-NN faz uso da distância das variáveis, uma que fosse grande demais poderia dominar o modelo ao fim do treinamento a normalização vem para punir essas variáveis.

Após normalização é feita a divisão do treino 80/20, o que foi feito para evitar que o modelo caísse em um conjunto desequilibrado. Então realizou-se a validação cruzada para encontrar o melhor **k**.

Por fim o treinamento final com o conjunto tendo o melhor k incluso.

3. RESULTADOS E DISCUSSÕES

No presente tópico segue a análise dos dados e respostas das questões pedidas pelo docente.


1) Preparação dos dados: carregue o dataset e recodifique a variável quality em três classes: notas ≤ 5 como ruim, 6–7 como médio e ≥ 8 como bom. Em seguida, normalize todos os atributos utilizando Min-Max ou Z-score. Justifique por que a normalização é uma etapa obrigatória para o k-NN.

Para que o modelo não seja dominado por variáveis muito grandes, como por exemplo, uma que varie de 0 à 1000, e outra que fique de 0 à 1, para que o modelo não trate a primeira como muito mais importante tem que ser feita a normalização.

2) Divisão treino/teste: divida os dados em 80% para treino e 20% para teste, utilizando divisão estratificada para garantir que a proporção das três classes seja mantida em ambos os conjuntos.

3) Treinamento e escolha do k: treine o modelo para diferentes valores de k (ex: 1, 3, 5, 7, 11) utilizando validação cruzada de 5 folds sobre o conjunto de treino. Plote a acurácia média em função de k e escolha o valor com melhor desempenho. O que acontece com o modelo para valores muito baixos e muito altos de k?

Figura1 - Acurácia média x k



O melhor k seria k = 47, como visto na figura 1, pois o mesmo apresenta maior acurácia.

Para valores muito baixos o modelo pode sofrer com overfitting, o que ocorreria em k=1, pois poderia apenas o modelo apenas copiar os dados somente e o mesmo ficaria sensível a ruído, já quando aumenta pode acabar suavizando demais o que geraria underfitting, o que ocorre em k = 2 à k = 8.

Em valores muito altos de k , a acurácia aumenta e então se estabelece em valores próximos.

4) Avaliação do modelo: utilizando o conjunto de teste — reservado exclusivamente para esta etapa — calcule a matriz de confusão e as métricas de acurácia, precisão, recall e F1-score para cada classe. Responda: Entre quais classes o modelo erra com mais frequência?

Figura 2 - matriz de confusão

$$\begin{pmatrix} 0 & 4 & 0 \\ 0 & 129 & 38 \\ 0 & 44 & 105 \end{pmatrix}$$

Tabela 1 - métricas

	precision	recall	f1-score	support
Bom	0.00	0.00	0.00	4
Medio	0.73	0.77	0.75	167
Ruim	0.73	0.70	0.72	149
Accuracy			0.73	320
macro avg	0.49	0.49	0.49	320
weighted avg	0.72	0.73	0.73	320

A classe bom foi teve apenas 4 amostras o que impediu o modelo de classificá-la devido a ser pequena, já as classes médio e ruim foram as em que o modelo mais errou como fica evidenciado na matriz de confusão (**figura 2**), sendo a classe ruim a pior com 70% de recall, onde 44 vinhos ruins foram ditos como médios. A classe média ficou um pouco menor com 38 vinhos médios classificados como ruins.


4. CONCLUSÃO

O modelo teve uma acurácia de 73% o que pode ser dito como aceitável, mas ela estaria no limiar, um pouco menor seria necessário uma reavaliação do modelo. O F1-score para médio e ruim indica que o modelo fez uma boa ponderância entre precisão e recall, com valores de 72% e 75% para as classes de médio e ruim, respectivamente, não tão próximo de 1 mas distante de zero, ou seja, proporcionalmente, o modelo teve poucos falsos negativos e falsos positivos.

O dataset teve poucas amostras de categoria “bom”, o que levou o modelo a nem sequer conseguir aprender os padrões para categorizá-las, contando apenas com 18 amostras em todo o mesmo. Também erros na categorização de “ruins” e “médios”, pois vinhos com notas entre 5 e 6 possuem características de qualidade muito próximas, o que leva a esse erro, seria necessário um conjunto maior de amostras para tal discrepância aumentar e diminuir os erros.

O modelo tem uma predição razoável para médios e ruins mas para a classe bons o modelo não conseguiu devido a pouca quantidades.

ANEXO I



The screenshot shows a Visual Studio Code editor window with a project named 'projeto03'. The Explorer sidebar on the left lists files: 'wine-quality', '.gitignore', '04_KNN.ipynb', 'main.pdf', 'modeloknn.py', 'projeto_knn.pdf', 'README.md', 'resultado.png', and 'wine-quality.zip'. The main editor displays the 'modeloknn.py' file with the following code:

```
27 y = dt['classe'].values
28
29 scaler = MinMaxScaler()
30 X = scaler.fit_transform(X)
31
```

The TERMINAL panel at the bottom shows the execution of the script using Python 3. The output includes cross-validated accuracy for different values of k, the best k value, a confusion matrix, and a classification report.

```
(venv) thiago@thiago-aspire-A315-53:~/Documentos/UFERSA/2026.1/SI/projetos/projeto03$ python3 modeloknn.py
k=43 -> acurácia média: 0.7217 ± 0.0241
k=44 -> acurácia média: 0.7170 ± 0.0233
k=45 -> acurácia média: 0.7209 ± 0.0266
k=46 -> acurácia média: 0.7170 ± 0.0254
k=47 -> acurácia média: 0.7240 ± 0.0265
k=48 -> acurácia média: 0.7178 ± 0.0241
k=49 -> acurácia média: 0.7162 ± 0.0208

Melhor k: 47

Matriz de Confusão:
[[ 0  4  0]
 [ 0 129 38]
 [ 0  44 105]]

Relatório de Classificação:
      precision    recall  f1-score   support

    bom         0.00         0.00         0.00         4
    medio        0.73         0.77         0.75        167
    ruim         0.73         0.70         0.72        149

 accuracy          0.49          0.49          0.49        320
 macro avg         0.49         0.49         0.49        320
 weighted avg      0.72         0.73         0.73        320

(venv) thiago@thiago-aspire-A315-53:~/Documentos/UFERSA/2026.1/SI/projetos/projeto03$
```

The status bar at the bottom indicates the current file is 'main.py', the editor is in 'main' mode, and the language is Python. The system clock shows 'abr 29, 13:27:02'.